732G53 Linjär regression – fusklapp

Notation: n = antal obs., k = antal förklarande variabler (lutningsparametrar), $p = k+1$ = antal parametrar, $df_E = n-(k+1)$. Källor: hietalai.github.io/statistics-in-r (Del II) och tentor 2024-10-25 – 2025-10-23.

1 Hitta rätt avsnitt – vanliga tentafrågor

b_0, b_1, ANOVA, test, KI/PI för hand (enkel regression)	§5, §6
Ange/kontrollera antagandena, tolka residualdiagram/QQ-plot	§2, §3
OLS-egenskaper, normalekvationer; korta svar på teorifrågor	§7, §29
Hypotesprövningens steg, p-värde	§8
Tolka koefficient, indikator, interaktion, R^2, intervall	§9, §18, §19
Läs R-utskrift, R^2 ur ANOVA-tabell, sekventiella SS	§11, §17
F-test för modellen / t-test för en parameter	§12, §14
Partiellt F: kvalitativ variabel, ”kan modellen reduceras?”	§13
Prediktion; flera intervall samtidigt (Bonferroni m.fl.)	§15, §16
Polynom, transformation, centrering	§20
Leverage, jackknife, DFFITS, Cook’s distance	§21
Korrelationsmatris, VIF, multikollinearitet	§22
Confounding, kontrollvariabel, Simpsons paradox	§23
Välj bästa modell, C_p, AIC, validering	§24, §25
Sant/falskt-påståenden; tabeller (t, F, χ^2, QQ)	§27, §32

2 Modell och antaganden

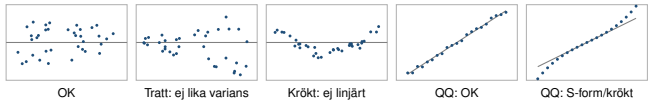
$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_k X_{ik} + E_i$, $E_i \overset{\text{iid}}{\sim} N(0,\sigma^2)$ $\Leftrightarrow$ $Y|X \overset{\text{iid}}{\sim} N(\mu_{Y|X}, \sigma^2)$ med $\mu_{Y|X} = E[Y|X] = \beta_0 + \beta_1 X_1 + \ldots$ (väntevärdet saknar felterm). Skattad modell: $\hat{y}_i = b_0 + b_1 x_{i1} + \cdots + b_k x_{ik}$ ($b_j = \hat{\beta}_j$); residual $e_i = y_i - \hat{y}_i$ skattar E_i. Minsta kvadratmetoden (OLS) väljer b_j som minimerar $\text{SSE} = \sum e_i^2$.

Antaganden (1) för varje X finns en slumpvariabel Y med ändligt medelvärde och varians; (2) oberoende observationer; (3) linjäritet: $\mu_{Y|X}$ linjär i parametrarna; (4) lika varians $\sigma^2_{Y|X} \equiv \sigma^2$ (homoskedasticitet); (5) $Y|X$ normalfördelad. **OBS!** Inget antagande om att Y självt är normalfördelat – kontrollera *residualerna*. Kontrollera antagandena *innan* test/intervall tolkas.

Kontroll (✓ = uppfyllt, ✗ = ej uppfyllt)

- **Linjäritet** – e mot $\hat{y}$ (och mot varje X_j). ✓ slumpmässig svärm kring 0 utan mönster. ✗ krökt/U-format mönster (även krökt QQ) ⇒ lägg till X^2, interaktion, saknad variabel eller transformera.
- **Lika varians** – e mot $\hat{y}$. ✓ jämnbrett band: två parallella linjer längs min/max ramar in punkterna. ✗ tratt/kon (spridningen ökar/minskar med $\hat{y}$) ⇒ transformera Y ($\ln Y$, $\sqrt{Y}$).
- **Normalfördelning** – histogram och QQ-plot av residualerna. ✓ symmetrisk klockform kring 0; punkterna följer linjen. ✗ skev, flera toppar (saknad gruppe-ringsvariabel), S-form/tunga svansar, extremvärden.
- **Oberoende** – e mot observationsordning (linjediagram) + hur data samlats in. ✓ inget mönster (”slump”). ✗ trender/vågor: tidsserier, upprepade mätningar på samma enhet, familjer, närliggande platser.

Litet n (t.ex. 6): svårt att bedöma – skriv det. *Formulering:* ”Residualerna ser approximativt normalfördelade ut: histogrammet är symmetriskt och klockformat kring 0 och punkterna i QQ-diagrammet följer linjen. Residualerna mot anpassade värden bildar ett jämnbrett band utan mönster ⇒ linjäritet och lika varians verkar uppfyllda.”



3 Läsa QQ-plot och residualmönster

- **QQ-plot** (observerade mot teoretiska kvantiler): längs linjen ⇒ normalfördelat. Båda ändarna *över* linjen (konvex) ⇒ högerskev; båda *under* (konkav) ⇒ vänsterskev; vänster ände under och höger över (S-form) ⇒ tunga svansar/extremvärden; tvärtom ⇒ lätta svansar; hopp/trappsteg ⇒ grupper. Krökt mönster kan också spegla icke-linjäritet (kurssidan).
- e **mot** $\hat{y}$**:** två eller flera band ⇒ saknad kategorisk variabel (mod_2 i tenta 2025-10-23); kors-/solfjädersmönster ⇒ saknad interaktion; enstaka punkt långt från 0 ⇒ möjligt extremvärde (kontrollera standardiserad/jackknife-residual, §21).
- **Histogram:** två toppar ⇒ grupper; skevt ⇒ transformera Y. e **mot ordning:** trender/vågor ⇒ beroende.

4 Utforskande analys och spridningsdiagram

Rita: förklarande X på x-axeln, respons Y på y-axeln, axeltitlar med enhet, rubrik. **Beskriv fyra saker:** (1) linjärt? (2) positivt/negativt? (3) starkt/svagt? (4) extremvärden? Kvalitativ X: fiol-/lådagram per kategori. Responsens histogram behöver *inte* vara normalfördelat. **Pearsons** r ($-1 \le r \le 1$) mäter bara *linjära* samband – missvisande vid krökta/icke-monotona samband och vid grupper (Simpsons paradox, §23); visualisera alltid. Korrelationsmatris: högt $|r(X_j,Y)| \Rightarrow$ relevant variabel; högt $|r(X_i,X_j)| \Rightarrow$ risk för multikollinearitet. Variabeltyper: kvalitativ (nominal-, ordinalskala) → indikatorer; kvantitativ (intervall-, kvotskala).

5 Enkel linjär regression – räkna för hand

$$S_{xx} = \sum(x_i-\bar{x})^2 = \sum x_i^2 - (\sum x_i)^2/n$$
$$S_{yy} = \text{SSY} = \sum(y_i-\bar{y})^2 = \sum y_i^2 - (\sum y_i)^2/n$$
$$S_{xy} = \sum(x_i-\bar{x})(y_i-\bar{y}) = \sum x_i y_i - \sum x_i \sum y_i/n$$

$b_1 = \dfrac{S_{xy}}{S_{xx}}$, $b_0 = \bar{y} - b_1\bar{x}$ (linjen går genom $(\bar{x},\bar{y})$; $\sum e_i = 0$, $\sum x_i e_i = 0$)

$\text{SSR} = b_1 S_{xy} = S_{xy}^2/S_{xx}$, $\text{SSE} = S_{yy} - b_1 S_{xy} = \sum(y_i-\hat{y}_i)^2$

$s^2 = \text{MSE} = \text{SSE}/(n-2)$, $s = \sqrt{\text{MSE}}$ (residualspridning)

$r = \dfrac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$, $R^2 = r^2 = \dfrac{\text{SSR}}{\text{SSY}}$, $b_1 = r\dfrac{s_y}{s_x}$

$s_{b_1} = \dfrac{s}{\sqrt{S_{xx}}}$, $s_{b_0} = s\sqrt{\dfrac{1}{n} + \dfrac{\bar{x}^2}{S_{xx}}}$

Test H_0: $\beta_1 = \beta_{10}$: $t = \dfrac{b_1 - \beta_{10}}{s_{b_1}} \sim t_{n-2}$; KI: $b_1 \pm t_{n-2;1-\alpha/2}\, s_{b_1}$

H_0: $\rho = 0$: $t = \dfrac{r\sqrt{n-2}}{\sqrt{1-r^2}}$ (samma t); $F = t^2$ (F-test $\equiv$ tvåsidigt t-test)

KI för medelvärdet $\mu_{Y|x_0}$: $\hat{y}_0 \pm t_{n-2;1-\alpha/2}\, s\sqrt{\dfrac{1}{n} + \dfrac{(x_0-\bar{x})^2}{S_{xx}}}$

PI för en ny obs. Y_0: $\hat{y}_0 \pm t_{n-2;1-\alpha/2}\, s\sqrt{1 + \dfrac{1}{n} + \dfrac{(x_0-\bar{x})^2}{S_{xx}}}$

Smalast vid $x_0 = \bar{x}$; PI alltid bredare än KI. Hävstång: $h_i = \frac{1}{n} + \frac{(x_i-\bar{x})^2}{S_{xx}}$. *Tips:* räkna i tabell med kolumnerna x, y, x^2, y^2, xy, $\hat{y}$, e, e^2 och behåll många decimaler i mellanleden.

6 Genomräknat exempel – tenta 2025-10-23, uppg. 1 ($n = 6$)

x = boendeyta (m^2), y = elkostnad (kr/år).

i	1	2	3	4	5	6	
x	207	168	165	99	176	139	$\sum = 954$
y	23546	20149	18971	12948	21532	14190	$\sum = 111\,336$
$\hat{y}$	23783.3	19536.1	19209.4	12021.8	20407.4	16377.9	
e	−237.3	612.9	−238.4	926.2	1124.6	−2187.9	$\sum = 0$
h_i	0.51	0.18	0.17	**0.70**	0.21	0.23	$\sum = p = 2$

$\sum x^2 = 158\,396$, $\sum y^2 = 2\,152\,928\,986$, $\sum xy = 18\,433\,163$, $\bar{x} = 159$, $\bar{y} = 18\,556$.
$S_{xx} = 158\,396 - 954^2/6 = 6710$; $S_{yy} = 86\,978\,170$; $S_{xy} = 18\,433\,163 - 954 \cdot 111\,336/6 = 730\,739$.

a) Spridningsdiagram boendeyta (x) mot elkostnad (y): starkt, positivt, linjärt samband.

b) $b_1 = 730\,739/6710 = 108.903$; $b_0 = 18\,556 - 108.903 \cdot 159 = 1240.43$
$\Rightarrow \hat{y} = 1240.43 + 108.90x$. *Tolkning:* varje extra m^2 ger i genomsnitt ca 109 kr/år högre elkostnad. b_0 tolkas ej ($x = 0$ ligger utanför data). $\text{SSR} = b_1 S_{xy} = 79\,579\,655$, $\text{SSE} = 7\,398\,515$, $\text{MSE} = \text{SSE}/4 = 1\,849\,629$, $s = 1360.0$, $R^2 = 0.915$ ($r = 0.957$): 91.5 % av variationen i elkostnad förklaras av boendeytan.

c) Antagandena och hur de kontrolleras: §2.

d) e mot $\hat{y}$: inget tydligt mönster, men $n = 6$ gör bedömningen osäker. QQ-plot: normalkvantilerna $\pm 0.21, \pm 0.67, \pm 1.38$ (tabell §32) mot sorterade e. Obs. 6 ($e = -2188$, $e/s = -1.61$, jackknife -3.9) avviker; obs. 4 ($x = 99$): $h = 0.70 > 2p/n = 0.67$, DFFITS $= 2.13 > 1$, Cook $= 1.85 > 1 \Rightarrow$ inflytelserik.

e) H_0: $\beta_1 \le 0$ (=0) mot H_a: $\beta_1 > 0$, $\alpha = 0.10$. $s_{b_1} = 1360.0/\sqrt{6710} = 16.603$; $t = 108.903/16.603 = 6.56 > t_{4;0.90} = 1.533 \Rightarrow$ förkasta H_0: boendeyta har en positiv effekt på elkostnaden ($p \approx 0.0014$).

f)

Källa	df	SS	MS	F
Regression	1	79 579 655	79 579 655	43.02
Residual	4	7 398 515	1 849 629	
Total	5	86 978 170		

H_0: $\beta_1 = 0$; $F = 43.02 > F_{1,4;0.95} = 7.71 \Rightarrow$ förkasta H_0: modellen är signifikant ($F = t^2 = 6.559^2$).

g) $x_0 = 150$: $\hat{y}_0 = 1240.43 + 108.903 \cdot 150 = 17\,575.9$

$s_{\hat{y}_0} = 1360.0\sqrt{\frac{1}{6} + \frac{(150-159)^2}{6710}} = 575.0$; $t_{4;0.975} = 2.776$

95 % KI: $17\,576 \pm 2.776 \cdot 575.0 = 17\,576 \pm 1\,596 = [15\,979;\ 19\,172]$ kr/år (PI för en enskild villa: $[13\,476;\ 21\,675]$). *Med 95 % konfidens täcker intervallet den genomsnittliga elkostnaden för villor på 150 m^2.*

7 Teori: minsta kvadratskattningarnas egenskaper

Normalekvationer ($\partial\text{SSE}/\partial b_0 = \partial\text{SSE}/\partial b_1 = 0$): $nb_0 + b_1\sum x_i = \sum y_i$ och $b_0\sum x_i + b_1\sum x_i^2 = \sum x_i y_i$; i matrisform $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$. **Residualerna:** $\sum e_i = 0$, $\sum x_i e_i = 0$, $\sum \hat{y}_i e_i = 0$, medelvärdet av $\hat{y}_i$ är $\bar{y}$. **Väntevärdesriktiga:** $E(b_j) = \beta_j$, $E(\text{MSE}) = \sigma^2$. Gauss–Markov: OLS har minst varians bland linjära väntevärdesriktiga skattningar (BLUE) under oberoende, $E(E_i) = 0$ och lika varians; normalfördelningen behövs för t-/F-test och intervall. **Enkel regression:** $\text{Var}(b_1) = \frac{\sigma^2}{S_{xx}}$, $\text{Var}(b_0) = \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)$, $\text{Cov}(b_0,b_1) = -\frac{\bar{x}\sigma^2}{S_{xx}}$, $\text{Var}(\hat{y}_0) = \sigma^2\left(\frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}\right)$, $\text{Var}(Y_0 - \hat{y}_0) = \sigma^2\left(1 + \frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}\right)$. Större spridning i x (större S_{xx}) $\Rightarrow$ säkrare b_1. **Multipel korrelation:** $R = \text{corr}(Y,\hat{Y})$ och R^2 är dess kvadrat. **Partiell korrelation:** $r^2_{YX_2\cdot X_1} = \text{SS}(X_2|X_1)/\text{SSE}(X_1)$ = andel av den kvarvarande variationen som X_2 förklarar. **Varför intercept?** Utan intercept tvingas linjen genom origo: sämre anpassning (större SSE), i allmänhet $\sum e_i \neq 0$ och R^2 blir missvisande.

8 Hypotesprövning – skriv ut alla steg

1. Hypoteser, t.ex. H_0: $\beta_j = 0$ mot H_a: $\beta_j \neq 0$ (> 0 eller < 0 om ensidigt) – även i ord.
2. Signifikansnivå α (anges i uppgiften, annars 0.05).
3. Testvariabel och dess fördelning under H_0: $t = \frac{b_j - 0}{s_{b_j}} \sim t_{n-p}$, $F \sim F_{df_1,df_2}$.
4. Beslutsregel: förkasta H_0 om $|t| > t_{n-p;1-\alpha/2}$ (tvåsidigt), $t > t_{n-p;1-\alpha}$ (H_a: $>$), $t < -t_{n-p;1-\alpha}$ (H_a: $<$), $F > F_{df_1,df_2;1-\alpha}$ (alltid ensidigt) – eller om p-värdet $< \alpha$.
5. Beräkna (visa insatta värden).
6. Beslut: förkasta / förkasta inte H_0.
7. Slutsats i ord i sammanhanget: ”På 5 % signifikansnivå finns stöd för att … har ett (positivt) samband med …”. Säg aldrig att H_0 är bevisad eller sann.

p-värde $= P$(minst lika extrem testvariabel $|$ H_0 sann) – *inte* $P(H_0$ sann). Tvåsidigt $p = 2P(T > |t|)$; R ger tvåsidigt $p \Rightarrow$ ensidigt $p/2$ om b_j har tecknet i H_a. Typ I-fel: förkasta sann H_0 (risk α); typ II-fel: behålla falsk H_0. $0 \notin 95$ %-KI $\Leftrightarrow$ förkasta H_0: $\beta_j = 0$ på 5 % (tvåsidigt).

9 Tolkningsmallar

- **Kvantitativ b_j:** ”När X_j ökar med en enhet förändras Y i genomsnitt med b_j enheter, givet att övriga variabler hålls konstanta.”
- **Indikator b_j:** ”Kategori A har i genomsnitt b_j enheter högre (lägre) Y än referenskategorin, givet …” – *inte* ”ökar med en enhet”.
- **Intercept b_0:** förväntat Y då alla $X = 0$; tolka bara om $X = 0$ finns i datas värdemängd. Behålls alltid i modellen.
- **R^2:** ”$100R^2$ % av variationen i Y förklaras av modellen.”
- **KI för β_j:** ”Med 95 % konfidens täcker intervallet den sanna genomsnittliga förändringen i Y när X_j ökar en enhet.”
- **KI** för $\mu_{Y|x_0}$ = genomsnittet för alla enheter med x_0; **PI** = en enskild ny observation (bredare).
- $\ln Y$ **som respons:** X_j ökar en enhet $\Rightarrow$ Y ändras ca $100(e^{b_j}-1)$ % ($\approx 100\,b_j$ % om $|b_j|$ litet).
- **Interaktion/polynom:** effekten av X beror på annan variabel resp. på X – summera alla termer som innehåller X (§19, §20).

10 Multipel regression i matrisform

$\mathbf{Y} = \mathbf{X}\beta + \mathbf{E}$; designmatrisen $\mathbf{X}$ ($n \times p$): första kolumnen ettor (intercept), sedan en kolumn per förklarande variabel (varje indikator räknas).

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}, \qquad \hat{\mathbf{Y}} = \mathbf{X}\hat{\beta} = \mathbf{H}\mathbf{Y}, \qquad \mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$$

$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I}-\mathbf{H})\mathbf{Y}$; $\mathrm{SSE} = \mathbf{e}'\mathbf{e} = (\mathbf{Y}-\mathbf{X}\hat{\beta})'(\mathbf{Y}-\mathbf{X}\hat{\beta}) = \mathbf{Y}'\mathbf{Y} - \hat{\beta}'\mathbf{X}'\mathbf{Y}$

$\mathrm{SSY} = \mathbf{Y}'\mathbf{Y} - \frac{1}{n}\mathbf{Y}'\mathbf{J}\mathbf{Y}$ ($\mathbf{J}$ = $n \times n$ ettor); $\mathrm{SSR} = \hat{\beta}'\mathbf{X}'\mathbf{Y} - \frac{1}{n}\mathbf{Y}'\mathbf{J}\mathbf{Y}$

$\mathrm{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$, skattas med $s^2(\hat{\beta}) = \mathrm{MSE}\,(\mathbf{X}'\mathbf{X})^{-1}$:
s_{b_j} = roten ur diagonalelement j; kovarianserna står utanför diagonalen.

Enkel regression: $\mathbf{X}'\mathbf{X} = \begin{bmatrix} n & \sum x \\ \sum x & \sum x^2 \end{bmatrix}$, $\mathbf{X}'\mathbf{Y} = \begin{bmatrix} \sum y \\ \sum xy \end{bmatrix}$, $(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{nS_{xx}}\begin{bmatrix} \sum x^2 & -\sum x \\ -\sum x & n \end{bmatrix}$.

2×2-invers: $\begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad-bc}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$. $\mathbf{X}'\mathbf{X}$ singulär (perfekt multikollinearitet, t.ex. c indikatorer för c kategorier) $\Rightarrow$ ingen invers. R: `X <- model.matrix(y ~ ., data); solve(t(X) %*% X) %*% t(X) %*% Y`.

11 ANOVA-tabell och R-utskrifter

Källa	df	SS	MS	F
Regression	k	$\mathrm{SSR} = \sum(\hat{y}_i - \bar{y})^2$	$\mathrm{MSR} = \mathrm{SSR}/k$	MSR/MSE
Residual	$n-k-1$	$\mathrm{SSE} = \sum(y_i - \hat{y}_i)^2$	$\mathrm{MSE} = \mathrm{SSE}/(n-k-1)$	
Total	$n-1$	$\mathrm{SSY} = \sum(y_i - \bar{y})^2$		

$\mathrm{SSY} = \mathrm{SSR} + \mathrm{SSE}$ (även df adderas): total = förklarad + oförklarad variation.
`anova(modell)` i R ger **sekventiella** (typ I) SS: rad 1 = $\mathrm{SS}(X_1)$, rad 2 = $\mathrm{SS}(X_2|X_1)$, rad 3 = $\mathrm{SS}(X_3|X_1,X_2)$, …; en kvalitativ variabel med c kategorier = en rad med $df = c-1$.

- SSR = summan av alla variabelrader; `Residuals` = SSE och MSE; SSY = summan av *alla* SS-rader.
- Radens $F = \mathrm{MS}_{\mathrm{rad}}/\mathrm{MSE}$ = partiellt F-test för variabeln givet raderna *ovanför*. Ordningen påverkar raderna men inte SSE, SSR, SSY.

`summary(modell)`: `Estimate` = b_j, `Std. Error` = s_{b_j}, `t value` = b_j/s_{b_j}, `Pr(>|t|)` = tvåsidigt p; `Residual standard error` = $s = \sqrt{\mathrm{MSE}}$ på $n-p$ df; `Multiple R-squared` = R^2; `Adjusted R-squared` = R^2_a; `F-statistic` på k och $n-p$ df.

Baklänges: $s_b = b/t$; $\mathrm{SSE} = s^2(n-p)$; $R^2 = 1 - \mathrm{SSE}/\mathrm{SSY}$; $F = \frac{R^2/k}{(1-R^2)/(n-p)}$; $\mathrm{SSY} = \mathrm{SSE}/(1-R^2)$.

Ex. R^2 ur R:s ANOVA-tabell: $R^2 = 1 - \mathrm{SSE}/\mathrm{SSY}$ där SSY = summan av alla SS inkl. `Residuals` (tentor 2024-10: 0.585; 2025-01: 0.764; 2025-02: 0.915).

12 F-test för hela modellen

H_0: $\beta_1 = \beta_2 = \cdots = \beta_k = 0$ mot H_a: minst ett $\beta_j \neq 0$.

$$F = \frac{\mathrm{SSR}/k}{\mathrm{SSE}/(n-k-1)} = \frac{\mathrm{MSR}}{\mathrm{MSE}} \sim F_{k,n-k-1}; \quad \text{förkasta om } F > F_{k,n-k-1;1-\alpha}$$

Förkastas H_0: minst en variabel har samband med Y – modellen är bättre än att bara använda $\bar{y}$ (säger inte *vilka*). Ej signifikant $\Rightarrow$ ingen idé att tolka vidare.

13 Partiellt F-test – grupp av s parametrar

H_0: de s testade $\beta = 0$ (t.ex. $\beta_3 = \beta_4 = \beta_5 = 0$) mot H_a: minst ett $\neq 0$. Komplett modell (F, k variabler) och reducerad modell (R, utan de s termerna, dvs. H_0 sann):

$$F = \frac{(\mathrm{SSE}_R - \mathrm{SSE}_F)/s}{\mathrm{SSE}_F/(n-k-1)} = \frac{(\mathrm{SSR}_F - \mathrm{SSR}_R)/s}{\mathrm{MSE}_F} = \frac{(R^2_F - R^2_R)/s}{(1-R^2_F)/(n-k-1)} \sim F_{s,n-k-1}$$

$s = df_{E,R} - df_{E,F}$; nämnarens df = residual-df i den *kompletta* modellen.
Sekventiellt: $\mathrm{SS}(X^*|X_1,\ldots,X_k) = \mathrm{SSE}_{X_1..X_k} - \mathrm{SSE}_{X_1..X_k,X^*} = \mathrm{SSR}_{X_1..X_k,X^*} - \mathrm{SSR}_{X_1..X_k} \geq 0$. Täljaren = SS(testade | övriga) = summan av de testade variablernas rader om de står *sist* i `anova()`. Flera variabler $\Rightarrow$ använd inte radernas p-värden. $\mathrm{SSR} = \mathrm{SS}(X_1) + \mathrm{SS}(X_2|X_1) + \mathrm{SS}(X_3|X_1,X_2) + \ldots$ (inte $\mathrm{SS}(X_1) + \mathrm{SS}(X_2) + \ldots$ om X:en är korrelerade).
Används för: kvalitativ variabel (alla $c-1$ indikatorer), interaktions-/polynomtermer, ”kan modell A reduceras till den nästlade modellen B?”. En enda variabel sist: partiellt $F = t^2$.
Specifika värden, t.ex. H_0: $\beta_2 = 4$, $\beta_5 = -2$: reducerad modell $Y^* = Y - 4X_2 + 2X_5 = \beta_0 + \beta_1 X_1 + \beta_3 X_3 + \beta_4 X_4 + E$.
Ex. (2024-10-25) Modell 3 (SSE = 83.5003, $df = 100$) mot modell 2 (SSE = 97.4415, $df = 108$): $s = 8$, $F = \frac{(97.4415-83.5003)/8}{0.8350} = 2.087 > F_{8,100;0.95} = 2.03 \Rightarrow$ förkasta H_0: kan *inte* reduceras ($p = 0.044$).
Ex. (2025-02-28) $s = 6$: $F = \frac{(38803.465-38136.618)/6}{90.586} = 1.227 < F_{6,421;0.95} = 2.12 \Rightarrow$ förkasta inte H_0: reducera till modell 2 ($p = 0.29$).

14 t-test och KI för en parameter

H_0: $\beta_j = 0$: $t = b_j/s_{b_j} \sim t_{n-k-1}$; KI: $b_j \pm t_{n-k-1;1-\alpha/2}\,s_{b_j}$. Testar om X_j bidrar *givet att övriga variabler finns i modellen*. Tas en icke-signifikant variabel bort $\Rightarrow$ anpassa om (alla b och s_b ändras) och analysera på nytt. Inte för kvalitativ variabel med flera nivåer ($\rightarrow$ partiellt F). Ta inte bort huvudeffekter som ingår i interaktion/polynom.

15 Prediktion i multipel regression

$\mathbf{x}_0 = (1, x_{01}, \ldots, x_{0k})'$: $\hat{y}_0 = \mathbf{x}_0'\hat{\beta}$; $s^2_{\hat{y}_0} = \mathbf{x}_0' s^2(\hat{\beta})\,\mathbf{x}_0 = \mathrm{MSE}\,\mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0$.

KI för $\mu_{Y|\mathbf{x}_0}$: $\hat{y}_0 \pm t_{n-p;1-\alpha/2}\,s_{\hat{y}_0}$; PI för ny Y_0: $\hat{y}_0 \pm t_{n-p;1-\alpha/2}\sqrt{\mathrm{MSE} + s^2_{\hat{y}_0}}$. Prediktera bara inom definitionsmängden (observerade X-värden) – kontrollera min/max! Centrerade/transformerade X: transformera $\mathbf{x}_0$ på samma sätt.

16 Simultan inferens (familjekonfidens)

g oberoende test på nivå α: $P(\geq 1 \text{ typ I-fel}) = 1 - (1-\alpha)^g$ (t.ex. $g = 20$: 0.64).

- **Bonferroni:** α/g per test/intervall, $B = t_{n-p;1-\alpha/(2g)}$: $b_j \pm B\,s_{b_j}$; $\hat{y}_0 \pm B\,s_{\hat{y}_0}$ (KI); $\hat{y}_0 \pm B\,s_{\mathrm{pred}}$ (PI). Bra när g är litet; bredare ju större g.
- **Working–Hotelling** (konfidensband för hela linjen, godtyckligt många $\mathbf{x}_0$): $\hat{y}_0 \pm W\,s_{\hat{y}_0}$, $W^2 = p\,F_{p,n-p;1-\alpha}$ (enkel regression: $W^2 = 2F_{2,n-2;1-\alpha}$). Beror inte på g.
- **Scheffé** (g prediktionsintervall): $\hat{y}_0 \pm S\,s_{\mathrm{pred}}$, $S^2 = g\,F_{g,n-p;1-\alpha}$, $s_{\mathrm{pred}} = \sqrt{\mathrm{MSE} + s^2_{\hat{y}_0}}$.

Välj metoden med minst multiplikator (B mot W, resp. B mot S).

17 Förklaringsgrad

$R^2 = \frac{\mathrm{SSR}}{\mathrm{SSY}} = 1 - \frac{\mathrm{SSE}}{\mathrm{SSY}} \in [0,1]$: andel förklarad variation. Ökar (minskar aldrig) när variabler läggs till – straffar *inte* komplexitet $\Rightarrow$ jämför inte modeller av olika storlek med R^2.

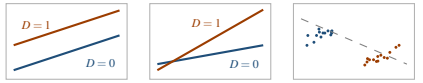
$R^2_a = 1 - \frac{\mathrm{SSE}/(n-k-1)}{\mathrm{SSY}/(n-1)} = 1 - (1-R^2)\frac{n-1}{n-k-1}$: straffar antalet variabler; högre = bättre; kan minska. Enkel regression: $R^2 = r^2$.

18 Indikatorvariabler (dummyvariabler)

Kvalitativ variabel med c kategorier $\Rightarrow$ $c-1$ indikatorer (0/1); utelämnad kategori = **referenskategori**. Alla c + intercept $\Rightarrow$ perfekt samband, $\mathbf{X}'\mathbf{X}$ singulär. Ex. art: Chinstrap = 1 om Chinstrap, annars 0; Gentoo = 1 om Gentoo, annars 0; Adelie = referens (båda 0).
b_j = genomsnittlig skillnad i Y mot referensen, givet övriga konstanta (parallellförskjuten linje: annat intercept, samma lutning). Hela variabeln testas med partiellt F (H_0: alla $c-1$ $\beta = 0$). R: gör variabeln till `factor` (numeriskt kodad 1/2/3 blir annars kvantitativ!). `region2`, `affiliation2` = indikator för nivå 2 jämfört med referensnivån 1.
Ex. (2025-02-28) `geographic_region2`, $b = 5.0046$: ”Kommuner i Mellanvästern har i genomsnitt ca 5 tusen fler anmälda allvarliga brott än kommuner i Nordost (referens), givet att övriga variabler hålls konstanta.”

19 Interaktioner

Kvalitativ × kvantitativ: $Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 XD + E$, $D \in \{0,1\}$:
$D = 0$: $Y = \beta_0 + \beta_1 X$; $D = 1$: $Y = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)X$.
β_2 = skillnad i intercept, β_3 = skillnad i lutning (effekten av X skiljer sig mellan grupperna). t-test av β_3: lika lutningar? Partiellt F för $\beta_2 = \beta_3 = 0$: identiska linjer? Fler kategorier $\Rightarrow$ en interaktion per indikator.
Ex. (2025-10-23, mod_4):
$\hat{y} = 3604.88 + 113.54\,\mathrm{Boyta} + 1857.10\,\mathrm{El} + 76.15\,\mathrm{Boyta}\cdot\mathrm{El} \Rightarrow$ ej eluppvärmd: $\hat{y} = 3604.88 + 113.54x$; eluppvärmd: $\hat{y} = 5461.98 + 189.69x$.
Kvantitativ × kvantitativ: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + E$: effekten av X_1 är $\beta_1 + \beta_3 X_2$ (beror på X_2) – tolka genom att fixera X_2 (t.ex. $\bar{x}_2$ och $\bar{x}_2 \pm s$) och visualisera.
Upptäck: grupperade spridningsdiagram (olika lutning per grupp), korsmönster i residualer mot X per grupp, X_1X_2 mot Y, mönster i residualdiagrammen. **Hierarki:** behåll huvudeffekterna (även om de inte är signifikanta) när interaktionen ingår. R: `y ~ x1*x2 = x1 + x2 + x1:x2`; `a*b*c*d` ger alla interaktioner upp till fjärde ordningen (15 termer) $\Rightarrow$ överanpassning, svårtolkat, höga VIF.



Indikator: parallella linjer | Interaktion: olika lutning | Simpsons paradox

20 Polynom och transformationer

$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + E$ är fortfarande en *linjär* modell (linjär i parametrarna) $\Rightarrow$ OLS. Används vid krökt samband (spridningsdiagram, krökta residualer); polynomen läggs till som separata variabler. R: `lm(y ~ x + I(x^2))` (utan `I()` blir det inget polynom).
Effekten av X: $d\hat{y}/dx = b_1 + 2b_2 x$ (beror på x); $b_2 > 0 \Rightarrow$ U-form, $b_2 < 0 \Rightarrow \cap$-form; extrempunkt i $x = -b_1/(2b_2)$. Tolka termerna tillsammans. Behövs krökningen? t-test för β_2 (partiellt F för flera högre termer).
Centrering $X_c = X - \bar{x}$: minskar korrelationen mellan X och X^2 (VIF) och beräkningsproblem. Ändrar b_0, b_1 och deras tolkning (b_1 = lutningen vid $x = \bar{x}$), men *inte* b_2, $\hat{y}$, residualerna, SSE eller R^2. Prediktion: centrera x_0 först!
Transformera Y: $\ln Y$ eller $\sqrt{Y}$ vid högerskeva residualer/ökande varians (tratt); $\ln X$ vid avtagande effekt. För hög polynomgrad $\Rightarrow$ modellen följer bruset (överanpassning).

21 Avvikande och inflytelserika observationer

- **Residual** $e_i = y_i - \hat{y}_i$, $\mathrm{Var}(e_i) = \sigma^2(1-h_i)$. **Standardiserad** $z_i = e_i/s$: antal standardavvikelser från residualernas medelvärde 0.
- **Studentiserad (intern)** $r_i = \frac{e_i}{s\sqrt{1-h_i}}$.
- **Jackknife** (externt studentiserad, `rstudent()`): residual från en modell anpassad *utan* obs. i:

$r_{(-i)} = e_i\sqrt{\dfrac{n-k-2}{\mathrm{SSE}(1-h_i)-e_i^2}} = r_i\sqrt{\dfrac{n-k-2}{n-k-1-r_i^2}} \sim t_{n-k-2}$; $|r_{(-i)}| > 2$–$3 \Rightarrow$ avvikande i Y-led.

- **Leverage** h_i = diagonalen i $\mathbf{H}$: $0 \le h_i \le 1$, $\sum h_i = p$, medel p/n; avvikande i X-led om $h_i > 2p/n$ (beror bara på X).
- **DFFITS**$_i = r_{(-i)}\sqrt{\dfrac{h_i}{1-h_i}}$: inflytande på *sitt eget* anpassade värde; gräns |DFFITS| > 1 (små/medelstora data), $> 2\sqrt{p/n}$ (stora data).
- **Cook's** $d_i = \dfrac{1}{p}\cdot\dfrac{h_i}{1-h_i}\cdot r_i^2$: inflytande på *alla* anpassade värden; gräns $d_i > 1$, eller robust: värde ur Kleinbaum tabell A.10 (n, k, α) delat med $n-(k+1)$.

Avvikande Y nära $\bar{x}$ (lågt h) flyttar linjen lite; högt h + avvikande $Y \Rightarrow$ stort inflytande; högt h men på linjen $\Rightarrow$ ofarlig.

Ex. (2024-10-25, $n = 20$ = litet): gräns 1 för båda; obs. 13: DFFITS $= -1.4$, Cook $= 0.9 \Rightarrow$ inflytelserik endast på sitt eget anpassade värde.

Ex. (2025-02-28, $n \approx 437$, $p = 10$): DFFITS-gräns $2\sqrt{10/437} \approx 0.30$; Cook $18.43/421 \approx 0.04 \Rightarrow$ flera inflytelserika obs.

Hantering: (1) leta mät-/inmatningsfel; (2) undersök obs.:ens X- och Y-värden – vad särskiljer den?; (3) ta bara bort med motivering (fel, annan population) och redovisa; (4) börja med den mest inflytelserika – övriga mått ändras när den tas bort, anpassa om; (5) jämför modellen med/utan.

22 Multikollinearitet

Starka samband *mellan* förklarande variabler. Följder: uppblåsta $s_{b_j} \Rightarrow$ icke-signifikanta t-test trots signifikant F; instabila skattningar, "fel" tecken; $\mathrm{SS}(X_2) \gg \mathrm{SS}(X_2|X_1)$ (variablerna förklarar samma variation). Prediktioner och R^2 påverkas mindre.

$\mathrm{VIF}_j = \dfrac{1}{1-R_j^2}$, R_j^2 från regression av X_j på övriga X (*utan* Y). VIF $= 5 \Leftrightarrow R_j^2 = 0.8$; VIF $= 10 \Leftrightarrow R_j^2 = 0.9$.

Tumregler: enskilt VIF > 10 eller medel-VIF $> 5 \Rightarrow$ hög risk. Parvis $|r| > 0.9 \Rightarrow$ överhängande risk (lösningsförslag). GVIF (kvalitativ variabel): $df = 1 \Rightarrow$ GVIF = VIF; annars jämför $\mathrm{GVIF}^{1/(2df)}$ med $\sqrt{5} \approx 2.24$ resp. $\sqrt{10} \approx 3.16$. Polynom/interaktioner ger artificiellt höga VIF – centrera och bedöm grundvariablerna (`vif(m, type="predictor")`).

Ex. (2024-10-25) Antal bäddar (VIF 35.7), patienter/dag (37.8), sjuksköterskor (7.5) har $r = 0.91$–0.98 sinsemellan $\Rightarrow$ multikollinearitet; modell 2 saknar dem (låg risk), modell 1 har två kvar.

Åtgärder: ta bort en av de korrelerade variablerna, kombinera dem (kvot/index), centrera, samla mer data.

23 Studiedesign, confounding, Simpsons paradox

Observationsstudie: vi observerar bara $\Rightarrow$ endast korrelationssamband, inga kausala slutsatser. **Experiment:** forskaren styr X (randomisering, kontroll) $\Rightarrow$ kausala slutsatser möjliga. Korrelation $\neq$ kausalitet (filmer med Nicolas Cage mot drunkningar).

Confounder (störfaktor): variabel som påverkar både X och $Y \Rightarrow$ skenbart/förvrängt samband. **Kontrollvariabel**: tas med i modellen för att justera (isolera) effekten av variabeln av intresse (t.ex. ålder och kön i en medicinstudie).

Simpsons paradox: ett samband som syns inom varje grupp försvinner eller byter riktning när grupperna slås ihop (näbbredd–näbblängd: positivt inom varje art, negativt totalt). Upptäck: färglägg spridnings-/residualdiagram efter grupp. Åtgärd: inkludera grupperingsvariabeln (ev. interaktion).

Ex. (2025-02-28, uppg. 3) e mot $\hat{y}$ markerat per art: Chinstrap har positiva residualer (underskattas), Gentoo negativa (överskattas) $\Rightarrow$ art påverkar sambandet och bör ingå i modellen.

24 Modellval och validering

Mått	Bäst
R^2	högt – men ökar alltid, ej för modeller av olika storlek
R_a^2	högt
$s = \sqrt{\mathrm{MSE}}$	lågt
Mallows $C_p = \dfrac{\mathrm{SSE}_p}{\mathrm{MSE}_{\text{full}}} - (n-2p)$	$C_p \approx p$ och litet (fulla modellen har alltid $C_p = p$)
$\mathrm{AIC} = n\ln(\mathrm{SSE}/n) + 2(p+1)$	lågt; straffar komplexitet, säger något om generaliserbarhet
$\mathrm{MSPR} = \frac{1}{n^*}\sum(y_i^* - \hat{y}_i^*)^2$	lågt, på valideringsdata; MSPR $\gg$ MSE $\Rightarrow$ överanpassad

(p = antal parametrar i delmodellen.) **Intern** validering: mått på träningsdata (R_a^2, AIC, C_p). **Extern**: dela data slumpmässigt i träning ($\ge 50\,\%$) och validering ($\ge 10\,\%$) och jämför MSPR; testmängd ger väntevärdesriktig skattning för den slutliga modellen; korsvalidering: m grupper turas om. Tidsserier: dela vid en tidpunkt. **Underanpassning**: för enkel, missar samband. **Överanpassning**: för komplex, modellerar bruset, generaliserar dåligt.

Algoritmer: best subsets (alla $2^k - 1$ modeller), bakåteliminering (från full modell, tar bort), framåtval (från tom, lägger till), stegvis (båda). Giriga – ser ett steg i taget, ger *inte* garanterat bästa modellen, känsliga för multikollinearitet, kan välja interaktion utan huvudeffekter. Bästa måttvärde $\neq$ lämplig modell $\Rightarrow$ alltid residualanalys och test efteråt. Kvalitativa variabler hanteras som en grupp (`factor`).

Ex. (2025-01-20) Största modellen (9 var.) bäst på R^2 och R_a^2; modell 8 bäst på C_p och AIC (straffar komplexitet $\Rightarrow$ mer tillförlitliga för generaliserbarhet). Boyta–antal rum $r = 0.815 < 0.9 \Rightarrow$ ingen överhängande multikollinearitetsrisk.

25 Välj modell – checklista och ex. 2025-10-23, uppg. 2

(1) **Lämplighet:** residualdiagram (mönster, varians, normalitet, extremvärden). (2) **Anpassning mot komplexitet:** R_a^2, AIC, C_p, s – välj den enklaste modell som förklarar i stort sett lika bra. (3) **Test:** F för modellen, partiellt F mellan nästlade modeller, t för termerna. (4) **Multikollinearitet:** korrelationsmatris, VIF. (5) **Tolkningsbarhet** och hierarki. (6) **Prediktion** inom definitionsmängden.

Modell	k	R_a^2	Bedömning
mod_1	5	0.918	5 huvudeffekter: krökt e mot $\hat{y}$ (saknar interaktion); Tomtyta–Boendeyta $r = 0.93$; Takhöjd och Tomtyta ej signifikanta
mod_2	3	0.418	utan Eluppvärmt: två grupper i e, S-formad QQ $\Rightarrow$ viktig variabel saknas (Eluppvärmt, $r = 0.74$ med Y)
mod_3	15	0.945	alla interaktioner upp till 4:e ordningen: bra residualer men överanpassad och svårtolkad
mod_4	3	0.941	Boendeyta × Eluppvärmt: slumpmässig svärm, rak QQ $\Rightarrow$ **välj**

Partiellt F (mod_4 är nästlad i mod_3): $F = \frac{(624\,728\,614 - 507\,449\,855)/12}{507\,449\,855/84} = 1.62 < F_{12,84;0.95} = 1.87 \Rightarrow$ extratermerna behövs inte. Modell-F för mod_4: $\frac{10\,260\,304\,836/3}{624\,728\,614/96} = 525.6 > F_{3,96;0.95} = 2.70$. Interaktion $t = 6.46 > t_{96;0.975} = 1.985 \Rightarrow$ effekten av boendeyta är större för eluppvärmda (189.7 mot 113.5 kr/m^2); Eluppvärmt ($t = 0.87$) behålls (hierarki). Prediktion (eluppvärmd, 200 m^2): $3604.88 + 113.54\cdot 200 + 1857.10 + 76.15\cdot 200 = 43\,400$ kr/år. Antal rum, takhöjd och tomtyta ingår inte i mod_4 (tomtyta 1700 > max 1523 hade dessutom varit extrapolering).

26 Utvärdera en modell – "Är modellen bra och lämplig?"

Lämplig = antagandena uppfyllda (§2): normalfördelning (histogram, QQ), lika varians och linjäritet (e mot $\hat{y}$), oberoende, extremvärden/inflytelserika observationer. **Bra** = högt R^2/R_a^2, signifikant F-test, rimliga och signifikanta koefficienter, ingen allvarlig multikollinearitet, lagom komplex. Avsluta med en samlad bedömning.

Ex. (2025-02-28, 1d) "Förklaringsgraden är hög (≈ 0.91) och modellen är signifikant enligt F-testet. Residualerna är ungefär normalfördelade (klockformat histogram, QQ-punkterna följer linjen) men det finns många extremvärden i båda riktningarna. Variansen ökar med större anpassade värden $\Rightarrow$ lika varians är inte uppfyllt. Extremvärdena bör undersökas (DFFITS, Cook's distance) och en transformation av Y övervägas."

27 Sant/falskt – påståenden från tidigare tentor

Uppgiften: markera 2 korrekta resp. 2 falska påståenden; fel markering ger -1 p $\Rightarrow$ markera bara det du är säker på. **S**= sant, **F**= falskt.

F F-test för modellen och partiellt F-test undersöker samma hypoteser. (Alla β resp. en delmängd.)

F Ett t-test kan avgöra om en kategorisk variabel med flera nivåer har samband med Y. (Partiellt F.)

S Kvantitativ variabel: "när variabeln ökar en enhet förändras Y med koefficientens värde" (givet övriga konstanta).

F Kategorisk variabel tolkas som "ökar med en enhet". (Jämförelse mot referenskategorin.)

F Normalfördelningen kontrolleras med histogram över responsvariabeln. (Över residualerna.)

S Stark korrelation mellan förklarande variabler riskerar problem med multikollinearitet.

S En kontrollvariabel justerar effekten av de andra variablerna för att hantera confounding.

F Jackknife-residualer anger residualen i enheten "standardavvikelser från residualernas medelvärde". (Det gör standardiserade residualer.)

S En kvalitativ variabel modelleras med en indikatorvariabel färre än antalet kategorier.

S Polynom kan modellera icke-linjära samband i en linjär modell.

S $\mathrm{SS}(X_2|X_1)$ beskriver hur mycket variation X_2 tillför en modell som redan innehåller X_1.

F Pearsons korrelationskoefficient är alltid lämplig för att mäta styrkan i ett samband. (Bara linjära.)

F Förklaringsgraden R^2 straffar modellen för antalet variabler. (Det gör R_a^2.)

S Den justerade förklaringsgraden straffar måttet utifrån antalet variabler i modellen.

F En låg justerad förklaringsgrad visar på en bättre modell.

S Cook's distance visar om en observation har inflytande på alla anpassade värden.

S DFFITS visar om en observation har inflytande på sitt eget anpassade värde.

F Framåtval, bakåteliminering eller stegvis regression leder alltid till den bästa modellen.

S Ett lägre AIC-värde är önskvärt när modeller jämförs.

F Det enda sättet att bedöma en modells generaliserbarhet är extern validering. (T.ex. AIC.)

F I en observationsstudie med två förklarande variabler är $\mathrm{SSY} = \mathrm{SS}(X_1) + \mathrm{SS}(X_2) + \mathrm{SSE}$. (Rätt: $\mathrm{SS}(X_1) + \mathrm{SS}(X_2|X_1) + \mathrm{SSE}$.)

S I enkel linjär regression testar t-testet för lutningen samma hypoteser som F-testet för modellen ($F = t^2$).

Fler troliga påståenden:

S R^2 kan aldrig minska när en variabel läggs till.

S Sekventiella SS beror på variablernas ordning; SSE och SSR gör det inte.

F Ett icke-signifikant intercept ska tas bort ur modellen.

S Prediktionsintervallet är bredare än konfidensintervallet för medelvärdet vid samma x_0.

F Hög leverage innebär alltid att observationen är inflytelserik.

F p-värdet är sannolikheten att H_0 är sann.

F En observationsstudie kan påvisa kausala samband.

S Centrering minskar multikollinearitet mellan X och X^2 utan att ändra $\hat{y}$ eller R^2.

F Bonferroniintervall blir smalare ju fler intervall som skattas.

S Ett signifikant F-test betyder att minst en (inte alla) lutningsparametrar är skild från 0.

28 Utblick: logistisk regression och GLM (kap. 10–11)

Binär Y: $\pi = P(Y=1|X)$, logitlänk $\ln\frac{\pi}{1-\pi} = \mathbf{x}'\beta \Leftrightarrow \pi = \frac{e^{\mathbf{x}'\beta}}{1+e^{\mathbf{x}'\beta}}$. Skattas med maximum likelihood (iterativt; kontrollera konvergens); ingen SSE/R^2. e^{b_j} =

oddskvot: oddset för $Y=1$ multipliceras med e^{b_j} när X_j ökar en enhet (övriga konstanta). Wald: $z=b_j/s_{b_j}\sim N(0,1)$; KI för OR: $e^{b_j\pm 1.96 s_{b_j}}$. LR-test (nästlade): $-2\ln(L_R/L_F)\sim\chi^2_s$. Förväxlingsmatris ($\hat\pi>0.5\Rightarrow\hat y=1$): träffsäkerhet $=\frac{f_{11}+f_{00}}{n}$, felkvot $=1-$träffsäkerhet, sensitivitet $=\frac{f_{11}}{f_{11}+f_{10}}$, specificitet $=\frac{f_{00}}{f_{01}+f_{00}}$ (obalanserade klasser $\Rightarrow$ titta på båda). Poisson (antal): $\ln\lambda=\mathbf{x}'\beta$; e^{b_j} = multiplikativ effekt på förväntat antal.

29 Teorifrågor – korta modellsvar

När används polynom, och hur anpassas och tolkas de? När sambandet mellan X och Y är icke-linjärt (krökt spridningsdiagram eller krökta residualer). Polynomtermerna ($X^2, X^3, \dots$) läggs till som separata variabler och modellen skattas med minsta kvadratmetoden (centrera gärna X). Effekten av X tolkas genom att summera alla termers bidrag (b_1+2b_2x), inte en term i taget.

Förklara Simpsons paradox. Ett samband som syns inom flera grupper försvinner eller byter riktning när grupperna slås ihop, t.ex. positivt samband mellan näbbredd och näbblängd inom varje pingvinart men negativt totalt. Paradoxen kan dölja eller förvränga sambanden i en regressionsmodell $\Rightarrow$ ta med grupperingsvariabeln.

Varför justerad förklaringsgrad? R^2 ökar alltid när variabler läggs till; R^2_a straffar antalet parametrar och kan därför jämföra modeller av olika storlek.

Varför inte t-test för en kategorisk variabel med flera nivåer? Variabeln motsvaras av $c-1$ parametrar; varje t-test jämför bara en kategori med referensen (och beror på valet av referens). Hela variabeln testas med partiellt F-test, H_0: alla $c-1$ parametrar $=0$.

KI eller PI? KI skattar medelvärdet $\mu_{Y|x_0}$ (osäkerheten i linjen); PI gäller en enskild ny observation och innehåller även σ^2 $\Rightarrow$ bredare, och krymper inte mot 0 när n växer.

Varför centrera? Minskar korrelationen mellan X och X^2 (eller interaktionstermer) $\Rightarrow$ lägre VIF, stabilare skattningar och tolkbart b_1 (effekten vid $\bar x$); anpassningen ($\hat y$, R^2) är densamma.

30 Tentatips

- Svarsbladet: numeriska svar med tre decimaler; uträkningar och tolkningar på separat papper. Redovisa, tolka och motivera!
- Saknas en siffra: skriv det, anta ett rimligt värde och lös vidare.
- df: residual $n-(k+1)$; kvalitativ variabel med c nivåer ger $c-1$ parametrar. Tabellavläsning och interpolering: §32.

31 Vanliga fel att undvika

- Fel df: MSE $=$ SSE$/(n-2)$ i enkel regression (inte $n-1$), allmänt $n-(k+1)$; i partiellt F tas nämnarens df från den *kompletta* modellen.
- Glömma ”i genomsnitt” och ”givet att övriga variabler hålls konstanta” i tolkningar.
- Ej förkastad $H_0\neq$ ”inget samband finns” – skriv ”inte tillräckligt stöd för …”.
- Kontrollera normalfördelning på Y i stället för på residualerna.
- t-test för kategorisk variabel med flera nivåer, eller radernas p-värden i `anova()` för flera variabler samtidigt ($\Rightarrow$ partiellt F).
- Jämföra R^2 mellan modeller av olika storlek ($\Rightarrow R^2_a$, AIC, C_p).
- Ta bort en huvudeffekt som ingår i en interaktion eller ett polynom.
- Blanda ihop KI (medelvärde) och PI (enskild observation).
- Extrapolera utanför observerade X-värden; glömma att centrera x_0 när modellen är centrerad.

32 Tabeller

t-fördelningen: $t_{df;q}$ med $P(T\le t_{df;q})=q$. Tvåsidigt test/KI på nivå α: $q=1-\alpha/2$; ensidigt: $q=1-\alpha$; Bonferroni: $q=1-\alpha/(2g)$ (0.9875: $g=2$, $\alpha=0.05$).

df	.90	.95	.975	.9875	.99	.995	.9995
1	3.078	6.314	12.706	25.452	31.821	63.657	636.619
2	1.886	2.920	4.303	6.205	6.965	9.925	31.599
3	1.638	2.353	3.182	4.177	4.541	5.841	12.924
4	1.533	2.132	2.776	3.495	3.747	4.604	8.610
5	1.476	2.015	2.571	3.163	3.365	4.032	6.869
6	1.440	1.943	2.447	2.969	3.143	3.707	5.959
7	1.415	1.895	2.365	2.841	2.998	3.499	5.408
8	1.397	1.860	2.306	2.752	2.896	3.355	5.041
9	1.383	1.833	2.262	2.685	2.821	3.250	4.781
10	1.372	1.812	2.228	2.634	2.764	3.169	4.587
11	1.363	1.796	2.201	2.593	2.718	3.106	4.437
12	1.356	1.782	2.179	2.560	2.681	3.055	4.318
13	1.350	1.771	2.160	2.533	2.650	3.012	4.221
14	1.345	1.761	2.145	2.510	2.624	2.977	4.140
15	1.341	1.753	2.131	2.490	2.602	2.947	4.073
16	1.337	1.746	2.120	2.473	2.583	2.921	4.015
17	1.333	1.740	2.110	2.458	2.567	2.898	3.965
18	1.330	1.734	2.101	2.445	2.552	2.878	3.922
19	1.328	1.729	2.093	2.433	2.539	2.861	3.883
20	1.325	1.725	2.086	2.423	2.528	2.845	3.850
21	1.323	1.721	2.080	2.414	2.518	2.831	3.819
22	1.321	1.717	2.074	2.405	2.508	2.819	3.792
23	1.319	1.714	2.069	2.398	2.500	2.807	3.768
24	1.318	1.711	2.064	2.391	2.492	2.797	3.745
25	1.316	1.708	2.060	2.385	2.485	2.787	3.725
26	1.315	1.706	2.056	2.379	2.479	2.779	3.707
27	1.314	1.703	2.052	2.373	2.473	2.771	3.690
28	1.313	1.701	2.048	2.368	2.467	2.763	3.674
29	1.311	1.699	2.045	2.364	2.462	2.756	3.659
30	1.310	1.697	2.042	2.360	2.457	2.750	3.646
35	1.306	1.690	2.030	2.342	2.438	2.724	3.591
40	1.303	1.684	2.021	2.329	2.423	2.704	3.551
50	1.299	1.676	2.009	2.311	2.403	2.678	3.496
60	1.296	1.671	2.000	2.299	2.390	2.660	3.460
80	1.292	1.664	1.990	2.284	2.374	2.639	3.416
100	1.290	1.660	1.984	2.276	2.364	2.626	3.390
120	1.289	1.658	1.980	2.270	2.358	2.617	3.373
∞	1.282	1.645	1.960	2.241	2.326	2.576	3.291

$F_{df_1,df_2;0.90}$ (10 %)

df_2	1	2	3	4	5	6	8	10
2	8.53	9.00	9.16	9.24	9.29	9.33	9.37	9.39
3	5.54	5.46	5.39	5.34	5.31	5.28	5.25	5.23
4	4.54	4.32	4.19	4.11	4.05	4.01	3.95	3.92
5	4.06	3.78	3.62	3.52	3.45	3.40	3.34	3.30
6	3.78	3.46	3.29	3.18	3.11	3.05	2.98	2.94
8	3.46	3.11	2.92	2.81	2.73	2.67	2.59	2.54
10	3.29	2.92	2.73	2.61	2.52	2.46	2.38	2.32
15	3.07	2.70	2.49	2.36	2.27	2.21	2.12	2.06
20	2.97	2.59	2.38	2.25	2.16	2.09	2.00	1.94
30	2.88	2.49	2.28	2.14	2.05	1.98	1.88	1.82
60	2.79	2.39	2.18	2.04	1.95	1.87	1.77	1.71
100	2.76	2.36	2.14	2.00	1.91	1.83	1.73	1.66
200	2.73	2.33	2.11	1.97	1.88	1.80	1.70	1.63
∞	2.71	2.30	2.08	1.94	1.85	1.77	1.67	1.60

$F_{df_1,df_2;0.99}$ (1 %)

df_2	1	2	3	4	5	6	8	10
2	98.50	99.00	99.17	99.25	99.30	99.33	99.37	99.40
3	34.12	30.82	29.46	28.71	28.24	27.91	27.49	27.23
4	21.20	18.00	16.69	15.98	15.52	15.21	14.80	14.55
5	16.26	13.27	12.06	11.39	10.97	10.67	10.29	10.05
6	13.75	10.92	9.78	9.15	8.75	8.47	8.10	7.87
8	11.26	8.65	7.59	7.01	6.63	6.37	6.03	5.81
10	10.04	7.56	6.55	5.99	5.64	5.39	5.06	4.85
15	8.68	6.36	5.42	4.89	4.56	4.32	4.00	3.80
20	8.10	5.85	4.94	4.43	4.10	3.87	3.56	3.37
30	7.56	5.39	4.51	4.02	3.70	3.47	3.17	2.98
60	7.08	4.98	4.13	3.65	3.34	3.12	2.82	2.63
100	6.90	4.82	3.98	3.51	3.21	2.99	2.69	2.50
200	6.76	4.71	3.88	3.41	3.11	2.89	2.60	2.41
∞	6.63	4.61	3.78	3.32	3.02	2.80	2.51	2.32

F-fördelningen, $F_{df_1,df_2;0.95}$ (5 % signifikans): täljar-df_1 i kolumner, nämnar-df_2 i rader.

df_2	1	2	3	4	5	6	7	8	10	12	15	20
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	241.9	243.9	245.9	248.0
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.40	19.41	19.43	19.45
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.79	8.74	8.70	8.66
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	5.96	5.91	5.86	5.80
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.74	4.68	4.62	4.56
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.06	4.00	3.94	3.87
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.64	3.57	3.51	3.44
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.35	3.28	3.22	3.15
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.14	3.07	3.01	2.94
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	2.98	2.91	2.85	2.77
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.85	2.79	2.72	2.65
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.75	2.69	2.62	2.54
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.67	2.60	2.53	2.46
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.60	2.53	2.46	2.39
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.54	2.48	2.40	2.33
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.49	2.42	2.35	2.28
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.45	2.38	2.31	2.23
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.41	2.34	2.27	2.19
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.38	2.31	2.23	2.16
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.35	2.28	2.20	2.12
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.32	2.25	2.18	2.10
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.30	2.23	2.15	2.07
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.27	2.20	2.13	2.05
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.25	2.18	2.11	2.03
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.24	2.16	2.09	2.01
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.22	2.15	2.07	1.99
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.20	2.13	2.06	1.97
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.19	2.12	2.04	1.96
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.28	2.18	2.10	2.03	1.94
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.16	2.09	2.01	1.93
35	4.12	3.27	2.87	2.64	2.49	2.37	2.29	2.22	2.11	2.04	1.96	1.88
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.08	2.00	1.92	1.84
50	4.03	3.18	2.79	2.56	2.40	2.29	2.20	2.13	2.03	1.95	1.87	1.78
60	4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	1.99	1.92	1.84	1.75
80	3.96	3.11	2.72	2.49	2.33	2.21	2.13	2.06	1.95	1.88	1.79	1.70
100	3.94	3.09	2.70	2.46	2.31	2.19	2.10	2.03	1.93	1.85	1.77	1.68
120	3.92	3.07	2.68	2.45	2.29	2.18	2.09	2.02	1.91	1.83	1.75	1.66
200	3.89	3.04	2.65	2.42	2.26	2.14	2.06	1.98	1.88	1.80	1.72	1.62
500	3.86	3.01	2.62	2.39	2.23	2.12	2.03	1.96	1.85	1.77	1.69	1.59
∞	3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.83	1.75	1.67	1.57

$\chi^2_{df;q}$ (LR-test, Wald z^2)

df	1	2	3	4	5	6	7	8	9	10
0.95	3.84	5.99	7.81	9.49	11.07	12.59	14.07	15.51	16.92	18.31
0.99	6.63	9.21	11.34	13.28	15.09	16.81	18.48	20.09	21.67	23.21

Normalkvantiler för QQ-plot för hand: $z_{(i-0.5)/n}$ för $i=1,\dots,\lceil n/2\rceil$ (resten symmetriska: byt tecken). Plotta sorterade residualer mot dessa.

n	$i=1$	2	3	4	5	6
5	−1.28	−0.52	0.00			
6	−1.38	−0.67	−0.21			
7	−1.47	−0.79	−0.37	0.00		
8	−1.53	−0.89	−0.49	−0.16		
9	−1.59	−0.97	−0.59	−0.28	0.00	
10	−1.64	−1.04	−0.67	−0.39	−0.13	
11	−1.69	−1.10	−0.75	−0.47	−0.23	0.00
12	−1.73	−1.15	−0.81	−0.55	−0.32	−0.10

Använda tabellerna. Saknas exakt df: ta närmast *lägre* df (konservativt) eller interpolera linjärt i $1/df$: $q\approx q_1+(q_2-q_1)\dfrac{1/df-1/df_1}{1/df_2-1/df_1}$; t.ex. $F_{6,421;0.95}$ ligger mellan $df_2=200$ (2.14) och 500 (2.12) $\Rightarrow\approx 2.12$. Samband: $F_{1,df;1-\alpha}=t^2_{df;1-\alpha/2}$, $t_{\infty;q}=z_q$, $t_{df;\alpha}=-t_{df;1-\alpha}$.

***p*-värde ur tabell:** se mellan vilka kolumner testvärdet hamnar, t.ex. $t=2.5$ med $df=20$: $2.086<2.5<2.528\Rightarrow 0.01<p<0.025$ ensidigt, $0.02<p<0.05$ tvåsidigt.